SentinelX AI

Dalil el EDA men el sfer

Chnowa 3malna fil notebook `01_eda_fd001_final_fusion.ipynb`, 3lech 3malnah, chnowa l9ina, w kifech tfasserha lel jury

> **Dataset :** NASA C-MAPSS — sous-ensemble FD001
> **Public :** débutant total — awel projet fil domaine
> **Langue :** derja tounsiya + termes techniques en français / anglais
> **Règle :** kol chiffre fil guide jey men l'exécution el 7a9i9iya mte3 el notebook

Projet d'intégration en Intelligence Artificielle — octobre 2026

Kifech te9ra el guide hedha

El guide hedha maktoub lel 7ad eli **ma ya3ref 7atta chay** 3al data science. Kol kelma technique nfassrouha ki tod5ol, w kol étape fil notebook nfassrou fiha 4 7ajet : **3lech** 3malneha, **chnowa ya3mel el code**, **chnowa l9ina** (les vrais résultats), w **kifech t9oulha lel jury**.

Ordre el 9raya el mounsa7 bih :

- **Parties 1 à 3** (el fekra el kbira, el vocabulaire, les statistiques) : e9rahom mrigla 9bal kol chay. Bla bihom, el notebook ma yetfhemch.
- **Partie 4** (el dataset) w **Partie 5** (Python minimum) : bech te9ra el code bla khouf.
- **Partie 6** : el notebook section b section. 7ell el notebook 7dhek w e9ra el zouz m3a ba3dhom.
- **Partie 7** : préparation lel soutenance — résumé, questions mte3 el jury w les réponses, erreurs à éviter.

Les encadrés :

Encadré	Chnowa fih
Fhemha b mithel	Mithel men el 7ayet el yawmiya bech el fekra tod5ol.
Chnowa l9ina	Les chiffres el 7a9i9iyin eli 5raj bihom el notebook.
Ndher — attention	Ghalta mte3 débutant lezem tetjanebha.
Kifech t9oulha lel jury	Jomla jehza bel français, t9oulha fil soutenance.
Ochfa — à retenir	El 7aja el wa7ida eli lezem tob9a fi rasek.

Sommaire

Partie 1 — El fekra el kbira 5

1.1 Maintenance prédictive : chnowa ? 5

1.2 SentinelX AI : chnowa el projet ? 5

1.3 El RUL : el kelma el mohemma barcha 5

1.4 Kifech el IA tet3allem ? 5

1.5 EDA : chnowa w 3lech 9bal el modèle ? 6

1.6 Win a7na fil projet ? 6

Partie 2 — El vocabulaire (glossaire) 7

Partie 3 — Les statistiques w les graphiques bel sahel 9

3.1 Moyenne, médiane, écart-type 9

3.2 Percentiles, quartiles, IQR 9

3.3 Kifech te9ra les graphiques 9

3.4 La corrélation 9

Partie 4 — El dataset NASA C-MAPSS FD001 11

4.1 El fichiers 11

4.2 El colonnes (26) 11

4.3 3lech FD001 ? 11

Partie 5 — Python minimum bech te9ra el code 12

5.1 groupby : el 7aja el mohemma fil projet 12

Partie 6 — El notebook section b section 13

Section 1 — Configuration et reproductibilité 13

Section 2 — Schéma du dataset et chargement 14

Section 3 — Contrôles de qualité et d'intégrité 14

Section 4 — Structure des trajectoires 15

Section 5 — Split train / validation par moteur 16

Section 6 — Variabilité des variables 17

Section 7 — Analyse temporelle des trajectoires 19

Section 8 — Construction et validation de la cible RUL 21

Section 9 — Distribution de la cible RUL 22

Section 10 — Relations variables–RUL : Pearson et Spearman 23

Section 11 — Robustesse des tendances au niveau moteur 25

Section 12 — Redondance entre variables 27

Section 13 — Audit anti-data-leakage 29

Section 14 — Contrôle structurel du jeu de test . . . 30
Section 15 — Export des artefacts . . . 32
Section 16 — Synthèse et décisions . . . 33
Section 17 — Conclusion scientifique . . . 33
Partie 7 — Préparation lel soutenance . . . 34
7.1 Résumé fi 60 seconde (a7fdhou) . . . 34
7.2 Questions probables mte3 el jury . . . 34
7.3 Erreurs lezem tetjanebhom fil oral . . . 35
7.4 Fiche mémo : les chiffres clés . . . 36

Partie 1 — El fekra el kbira

1.1 Maintenance prédictive : chnowa ?

Fama 3 tourou9 bech tsa77a7 machine :

Type	Ma3neha	Mochkla
Maintenance **corrective**	Testanna 7atta tetkasser, ba3d tsa77a7.	Panne surprise, ghalia w mkharba lel production.
Maintenance **préventive**	Tbaddel les pièces kol modda fixe (ex. kol 10 000 km).	Marrat tbaddel pièce mezelet behya → masrouf zeyed.
Maintenance **prédictive**	Tchouf el capteurs w t9oul : « el moteur hedha yab9a 7al 40 cycle ».	Lezemha data w modèle IA — w houni yod5ol SentinelX AI.

> **Fhemha b mithel**
>
> Karhbtek : el maintenance corrective = testanna 7atta tetwa99ef fil autoroute. El préventive = tbaddel el zit kol 10 000 km mahma kenet 7altou. El prédictive = el tableau de bord y9ollek « el frein bech youfa fi 2 000 km » 5atr chef el capteurs.

1.2 SentinelX AI : chnowa el projet ?

SentinelX AI howa plateforme **100 % logicielle** (bla matériel) eli :

- ta9ra data capteurs mte3 moteurs d'avion (dataset NASA C-MAPSS) ;
- t9addar **9adech yab9a 3omr el moteur** (el RUL) ;
- tdetecti les comportements anormaux w ta3ti **Health Score** (note de santé de 0 à 100) ;
- 3andha **copilote RAG** : chatbot yjaweb 3la as2ila mte3 el maintenance w y9ollek men ama document jeb el réponse.

1.3 El RUL : el kelma el mohemma barcha

RUL = Remaining Useful Life = durée de vie utile restante = **9adech men cycle yab9a 9bal el panne**.

> **Fhemha b mithel**
>
> Moteur bech ytaya7 fil cycle 200. Taw a7na fil cycle 150. Donc **RUL = 200 − 150 = 50 cycles**. Fil cycle 199, RUL = 1. Fil cycle 200 (el panne), RUL = 0.
>
> El IA mte3na lezem tet3allem : **men valeurs el capteurs → t9addar el RUL**.

1.4 Kifech el IA tet3allem ?

Hedha esmou **apprentissage supervisé** (supervised learning) :

- N3atiw lel **modèle** barcha amthla : « capteurs bel valeurs hedhom → RUL kadha ». Les capteurs esmhom **features** (X), el RUL esmou **target** ou **cible** (y).
- El modèle yel9a wa7dou el 3ala9a bin X w y.
- Ba3d n3atiwah moteur **jdid** ma chafouch 9bal, w y9addar el RUL mte3ou.

Fhemha b mithel

Tlamidh y7adhrou lel bac :

- **Train** (entraînement) = exercices m7loulin, y9raw menhom.
- **Validation** = examen blanc, bech n3arfou chkoun fhem w nbadlou tari9et el 9raya.
- **Test** = el bac. Ma y7elouhch 7atta l'e5er.

Ken tlamidh **chef les réponses mte3 el bac 9bal**, yjib 20 ama ma fhem chay. Hedha esmou **data leakage** (fuite de données) — w houwa el 3dou numéro 1 fil projet hedha.

1.5 EDA : chnowa w 3lech 9bal el modèle ?

EDA = Exploratory Data Analysis = analyse exploratoire des données. Hiya el **marhla el oula** : nchoufou el data w nefhmouha **9bal** ma nebniw ay modèle.

Fhemha b mithel

Tbib 9bal ma yekteblek dwe, ya3mel analyses w ychouf el 7ala. Ma ynajjemch yekteb dwe bla ma yefhem chnowa 3andek. El EDA hiya el « analyses » 9bal el « dwe » (el modèle).

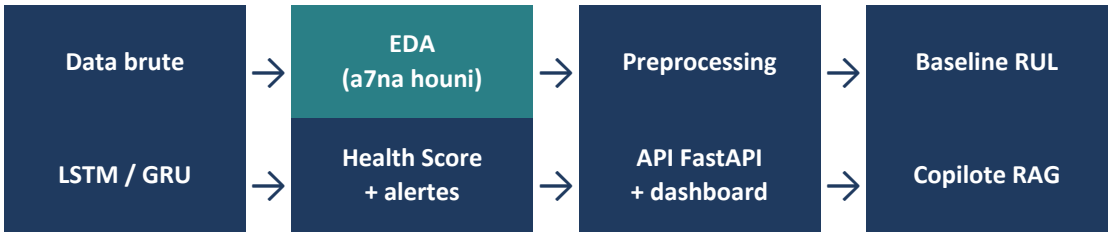
El EDA tjaweb 3la as2ila kif :

- El data **nadhifa** ? (cases fer8in, doublons, erreurs ?)
- El data **kifech mbniya** ? (9adech men moteur, 9adech men cycle ?)
- Ama variables **ma ta3ti 7atta information** ?
- Ama variables **tetbadel m3a el RUL** ?
- Fama **pièges** (fuite d'information) lezem nsakrouhom ?

Ndher — attention

El EDA **ma tentrainich modèle** w **ma takhtarch** les features definitivement. Hiya tlawwa7 **hypothèses** (fekrat), w el modèle ba3d howa eli y2akkedhom wala la.

1.6 Win a7na fil projet ?



Fil cahier des charges, el EDA hiya l'exigence **F-02** w el semaine **S2**. Kol chay ba3dha yetbna 3liha : ken el EDA ghalta, el projet lkol yetkasser.

Ochfa — à retenir

EDA = **nefhem el data 9bal ma nebni el modèle**, w nsakker les pièges (surtout el data leakage).

Partie 2 — El vocabulaire (glossaire)

Hedhom el kelmet eli bech tetla9ahom fil notebook w fil soutenance. Matestanech t7fadhhom lkol mel marra el oula : erja3 lel tableau hedha kol ma tel9a kelma ma fhemtehech.

Kelma	Ma3neha bel derja	Mithel fil projet
Dataset (jeu de données)	Majmou3a mte3 data m7adhra fi tableau.	`train_FD001.txt`, `test_FD001.txt`
Ligne / colonne	Ligne = observation wa7da ; colonne = variable wa7da.	Ligne = moteur 8 fil cycle 148
DataFrame	Tableau fi Python (bibliothèque pandas).	`train_df`, `analysis_train`
Variable / feature	Information n3atiwha lel modèle bech y9arrer.	`sensor_11`, `cycle`
Target / cible	El 7aja eli n7ebbou nprédictiwha.	`RUL`
unit_id	Numéro el moteur.	moteur 1 … 100
Cycle	« Vol » wa7ed mte3 el moteur = unité de temps.	cycle 1, 2, 3 …
Capteur (sensor)	Appareil y9is 7aja fil moteur (température, pression…).	`sensor_1` … `sensor_21`
Setting	Condition de fonctionnement mte3 el moteur.	`setting_1` … `setting_3`
Trajectoire	Kol el cycles mte3 moteur wa7ed men lowel lel e5er.	moteur 26 : 199 cycles
Train / validation / test	Data lel ta3lim / examen blanc / examen final.	80 / 20 moteurs ; test NASA
Split	9asma mte3 el data 3la zouz (wala akther) ensembles.	split par moteur 80 / 20
Modèle	Programme yet3allem el 3ala9a bin X w y.	Ridge, Random Forest, LSTM
Overfitting (surapprentissage)	Modèle y7fadh el amthla bla ma yefhem → ytaya7 3al jdid.	tlamidh y7fadh les réponses
Data leakage (fuite)	Information mel mosta9bel wala mel test tod5ol lel ta3lim → résultats mgharrin.	colonne `last_cycle`
Seed / random_state	Raqm yfixi el « hasard » bech nafs el résultat yarja3.	`RANDOM_STATE = 42`
Moyenne (mean)	Majmou3 el valeurs 9sem 3la 3adadhom.	moyenne des longueurs = 206,31
Médiane	El valeur eli fil wost ki nratbou el valeurs.	médiane des longueurs = 199
Écart-type (std)	9adech el valeurs mfar9in 3al moyenne.	46,34 cycles
Percentile / quartile	P25 = 25 % mel valeurs a9al menha. Q1 = P25, Q3 = P75.	Q1 = 177, Q3 = 229,25
IQR	Q3 − Q1 : 3ordh el 50 % mte3 el wost.	229,25 − 177 = 52,25
Outlier (valeur atypique)	Valeur b3ida barcha 3al o5rin.	moteur 69 (362 cycles)
Distribution	Kifech el valeurs mwaz3in.	barcha moteurs bin 177 w 229 cycles
Histogramme	Graphique b barres : 9adech men valeur fi kol tranche.	Figure section 4
Box-plot	« Bwata » : el wost mte3 el data + moustaches + outliers.	Figure section 4
ECDF	Courbe cumulée : 9adech men % mel valeurs a9al men x.	Figure section 5
Corrélation	Raqm bin −1 w +1 : kifech zouz variables ymchiw m3a ba3dhom.	`sensor_11` / RUL = −0,71
Pearson	Corrélation **linéaire** (ligne droite).	Section 10
Spearman	Corrélation **monotone** (dima tzid wala dima tan9es).	Section 10
Monotone	Dima fi nafs el ittijah, 7atta ken mouch b nafs el sor3a.	capteur dima yetla3

Kelma	Ma3neha bel derja	Mithel fil projet
Redondance	Zouz variables y9oulou nafs el 7aja.	`sensor_9` / `sensor_14` : 0,97
Moyenne glissante (rolling mean)	Moyenne 3al N cycles lekhrin : tna77i el bruit.	`ROLLING_WINDOW = 10`
Causal	Yesta3mel ken el madhi, kif fil production.	moyenne glissante causale
Fenêtre W (window)	9adech men cycle el modèle ychouf fard marra.	W = 20, 30 ou 50
Padding	N3abbiw valeurs zeydin ki el historique 9sir 3al fenêtre.	moteur test de 31 cycles avec W = 50
Scaler (normalisation)	Yrodd les variables fi nafs el échelle.	StandardScaler (étape 02)
Hyperparamètre	Choix nekhtarouh a7na 9bal el ta3lim.	W, plafond du RUL
Baseline	Modèle basit bech n9arnou bih el modèles el kbar.	Ridge, Random Forest
Ablation	Nna77iw variable w nchoufou el performance tetbadel wala la.	avec / sans `sensor_6`
GroupKFold	Validation croisée par groupes : kol moteur yet3adda marra fil validation.	étape 02
RUL plafonné (capped)	RUL 3lih maximum (ex. 125).	hypothèse, section 8
SMD	Far9 bin zouz moyennes 9sem 3al écart-type.	section 14
assert	Ligne code twa99ef el notebook ken chart ghalet.	`assert len(overlap) == 0`
Artefact	Fichier ysajjel résultat bech nesta3mlouh ba3d.	`fd001_engine_split.json`
SHA-256	« Empreinte digitale » mte3 fichier.	`963b5e22…` (train)

Partie 3 — Les statistiques w les graphiques bel sahel

3.1 Moyenne, médiane, écart-type

Ta5ou 5 moteurs, kol wa7ed 3ach 9adech men cycle : **150, 180, 200, 210, 360**.

- **Moyenne** = (150 + 180 + 200 + 210 + 360) / 5 = 1 100 / 5 = **220**.
- **Médiane** = el valeur eli fil wost ki nratbou : **200**.
- El moyenne (220) akber mel médiane (200) 5atr el moteur **360** « yejbedha » lel fou9. El médiane ma tet2assarch b el valeurs el b3ida : 3lech nesta3mlouha barcha.
- **Écart-type** : y9is 9adech el valeurs mfar9in 3al moyenne. Ken el moteurs lkol 3achou 200 cycle, écart-type = 0. Kol ma yetfar9ou, ykbar.

> **Ochfa — à retenir**
>
> Ki **moyenne > médiane**, el distribution **asymétrique à droite** : fama valeurs kbar barcha « yejbdou » el moyenne. Hedha bedhabt chnowa l9ina fil section 4 (206,31 contre 199).

3.2 Percentiles, quartiles, IQR

- **P5 = 147** ya3ni 5 % mel moteurs 3achou a9al men 147 cycle.
- **Q1 (P25)**, **médiane (P50)**, **Q3 (P75)** : y9assmou el data 3la 4 ajzé2 kif kif.
- **IQR = Q3 − Q1** : 3ordh el 50 % el wostaniyin. Fil train : 229,25 − 177 = 52,25.
- **Règle de Tukey** : valeur akber men Q3 + 1,5 × IQR = **atypique** (outlier). Fil train : 229,25 + 1,5 × 52,25 = **307,6 cycles**.

3.3 Kifech te9ra les graphiques

Graphique	Kifech te9rah	Win fil notebook
Histogramme	Kol barre = tranche de valeurs ; tolha = 9adech men observation fiha. Ychouflek win el valeurs mtlemmin.	Sections 4, 9, 14
Box-plot	El bwata = men Q1 lel Q3 ; el trait fil wost = médiane ; les moustaches = el valeurs « normales » ; les points = outliers.	Sections 4, 11
ECDF	Courbe tetla3 men 0 lel 1. Fil point x, el hauteur = el part mel valeurs a9al men x. Zouz courbes 9rab = zouz distributions mtchabhin.	Section 5
Courbe dans le temps	Axe x = cycle (wala RUL), axe y = valeur el capteur. Tchouf kifech yetbadel m3a el wa9t.	Sections 7, 11
Heatmap	Tableau b alwen : a7mar = corrélation positive, azre9 = négative, bidh = 0.	Section 12
Dendrogramme	Chajra : zouz capteurs yetla9aw fi distance sghira = mtchabhin barcha.	Section 12

3.4 La corrélation

La corrélation hiya raqm **bin −1 w +1** y9is kifech zouz variables ymchiw m3a ba3dhom :

- **+1** : ki wa7da tzid, lo5ra tzid dima.

- **−1** : ki wa7da tzid, lo5ra tan9es dima.
- **0** : ma fama 7atta 3ala9a (men el naw3 el mi9yes).
- Fil notebook, |corrélation| (bla signe) **fou9 0,5** = 3ala9a wadh7a ; **fou9 0,8** = 9wiya barcha.

Pearson wala Spearman ?

Ta5ou x = 1, 2, 3, 4, 5 w y = 1, 2, 4, 8, 16 (y dima tzid, ama dima b sor3a akber) :

x	1	2	3	4	5
y	1	2	4	8	16

- **Spearman = 1** : y dima tzid ki x tzid → relation **parfaitement monotone**.
- **Pearson ≈ 0,93** : el no9at mouch 3la ligne droite → relation **mouch linéaire**.
- Ki **Spearman > Pearson**, el relation monotone ama **ma7nia** (courbe). Hedha bedhabt chnowa l9ina fil capteurs mte3 C-MAPSS.

> **Ndher — attention**
>
> **Corrélation ≠ causalité.** Fil sif, bi3 el glace w ta7ri9 el chams yetla3ou m3a ba3dhom, ama el glace ma ta3melch ta7ri9 : el sbab howa el sif. Kif-kif, ki capteur yetbadel m3a el RUL, ma n9oulouch « el capteur hedha howa sbab el panne ».

Partie 4 — El dataset NASA C-MAPSS FD001

C-MAPSS = *Commercial Modular Aero-Propulsion System Simulation*. NASA 3amlet **simulation** mte3 moteurs d'avion (turbofan) men el bidaya 7atta el panne, w sajjlet el capteurs fi kol cycle.

> **Fhemha b mithel**
>
> Kol **moteur** = avion. Kol **cycle** = vol. Les **capteurs** = el tableau de bord eli ysajjel température, pression, vitesses… fi kol vol. Les **settings** = kifech el pilote 5addem el avion.

4.1 El fichiers

Fichier	Fih chnowa	Nesta3mlouh fil EDA ?
`train_FD001.txt`	100 moteurs, kol wa7ed men cycle 1 **7atta el panne**. 20 631 lignes.	Ey
`test_FD001.txt`	100 moteurs o5rin, **ya9ta3** 9bal el panne. 13 096 lignes.	Ey, ama ken les **entrées** (contrôles)
`RUL_FD001.txt`	El **réponses** : el RUL el 7a9i9i mte3 kol moteur test.	**La, jamais** — réservé lel évaluation finale

4.2 El colonnes (26)

Colonne	Ma3neha
`unit_id`	Numéro el moteur (1 à 100).
`cycle`	Numéro el cycle (yebda men 1 w yzid b 1).
`setting_1` à `setting_3`	Conditions de fonctionnement fil cycle hedha.
`sensor_1` à `sensor_21`	21 mesure mte3 capteurs. El fichier **ma y9ollekch** chnowa kol capteur (température wala pression…) : ghir numéros.

4.3 3lech FD001 ?

C-MAPSS fih 4 sous-ensembles (FD001 à FD004). **FD001 howa el as7el** : **1 condition** de fonctionnement w **1 mode de panne**. El cahier des charges y9ol : « Commencer par FD001 pour obtenir rapidement une chaîne complète ».

> **Ochfa — à retenir**
>
> **Ligne = moteur fi cycle mo3ayyen**, mouch moteur kamel. 20 631 ligne = 100 moteur × barcha cycles.

Partie 5 — Python minimum bech te9ra el code

Ma tes7a99ech tkoun développeur. Yekfi tefhem el 7ajet hedhi :

Code	Ma3neha
`import pandas as pd`	Jib el bibliothèque pandas w semmiha `pd` (bech nekhtasrou).
`x = 42`	Variable : 3olba esmha `x` fiha 42.
`[1, 2, 3]`	Liste : sel3a mratba.
`{"a": 1}`	Dictionnaire : esm → valeur.
`def f(df): ...`	Fonction : bloc code nesta3mlouh barcha marrat.
`[f"sensor_{i}" for i in range(1, 22)]`	Yasna3 liste : sensor_1, sensor_2 … sensor_21 (`range(1, 22)` = 1 … 21, el 22 ma yetkhalech).
`df["cycle"]`	Ta5ou colonne `cycle` mel tableau `df`.
`df.groupby("unit_id")["cycle"].max()`	Lkol moteur, a3tini akber cycle (= toul 3omrou).
`df.describe()`	Ya3ti moyenne, écart-type, min, quartiles, max.
`assert condition, "message"`	Ken el condition ghalta → el notebook yo9ef w ykteb el message.
`print(f"Total : {n}")`	Yekteb texte, w `{n}` yetbaddel b valeur `n`.
`fig, ax = plt.subplots()`	Yasna3 graphique fergh (`fig`) w zone de dessin (`ax`).

5.1 groupby : el 7aja el mohemma fil projet

`groupby("unit_id")` ya3ni « 9assem el tableau 3la moteurs, w a3mel el calcul lkol moteur wa7dou ».

Mithel sghir

```
unit_id  cycle            df.groupby("unit_id")["cycle"].max()
   1       1
   1       2             unit_id
   1       3      ──►       1        3
   2       1                2        2
   2       2
```

Moteur 1 3ach 3 cycles, moteur 2 3ach 2 cycles. Hedhi el fonction `trajectory_lengths` fil notebook.

> **Fhemha b mithel**
>
> `transform("max")` y3ayet nafs el calcul, ama **yrodd el résultat fi kol ligne** mte3 el moteur (moteur 1 : 3, 3, 3). Nesta3mlouha bech nebniw el RUL (section 8).

Partie 6 — El notebook section b section

El notebook fih **85 cellule** w **17 section**. Fil bidaya fih tableau b **9 as2ila (Q1 à Q9)**, w el conclusion tjaweb 3lihom lkol. El logique :

```
Configuration → Chargement → Qualité → Trajectoires → SPLIT → Variables → Temps
     → Cible RUL → Distribution RUL → Corrélations → Robustesse → Redondance
     → Audit leakage → Contrôle du test → Export → Synthèse → Conclusion
```

> **Ndher — attention**
> El **split** (section 5) jé **9bal** el analyses. 3lech ? 5atr ki nchoufou corrélations w n5tarou capteurs, lezem nchoufou ken data el ta3lim. Ken nchoufou el validation zeda, « ghachachna » fil examen blanc.

Section 1 — Configuration et reproductibilité

3lech : bech kol 7ad yet3awed el notebook (enti ba3d chhar, el encadrant, el jury) yel9a **nafs el résultats bedhabt**. Hedha esmou **reproductibilité**.

Cellule 2 — extrait

```
RANDOM_STATE = 42                  # graine unique pour tout le hasard
VALIDATION_SIZE = 0.20             # 20 % des moteurs en validation
NEAR_CONSTANT_THRESHOLD = 0.95     # seuil « quasi constante »
STRONG_CORR_THRESHOLD = 0.80       # seuil de redondance
ROLLING_WINDOW = 10                # moyenne glissante sur 10 cycles
```

- Kol **seuil** (raqm n5tarouh a7na) mektoub **marra wa7da** fil bidaya. Ki n7ebbou nbadlouh, nbadlouh fi blasa wa7da. Ma famech « 3dad sa7riya » mtla77in fil code.
- `RANDOM_STATE = 42` : el ordinateur ki ya3mel « hasard », yesta3mel 3dad. Ki nfixiw el graine, el hasard yarja3 nafsou kol marra. 42 ma 3andou 7atta ma3na 5ass : tradition.
- El notebook yaffichi **les versions** des bibliothèques (Python 3.14.7, pandas 3.0.6, numpy 2.5.3, scikit-learn 1.9.1…) : version o5ra tnajjem ta3ti résultat mokhtalef chwaya.

Les fonctions utilitaires (1.2)

```
def trajectory_lengths(df):
    """Dernier cycle observé de chaque moteur."""
    return df.groupby("unit_id")["cycle"].max().rename("n_cycles")
```

Nekteb el contrôles fi **fonctions** (`quality_report`, `trajectory_lengths`…) bech nesta3mlouhom 3al **train** w 3al **test** bla copier-coller. Nafs el fonction = nafs el contrôle bedhabt.

L'empreinte SHA-256 (1.3)

`file_sha256` ya3ti « empreinte digitale » lkol fichier. Ken tbadlet 7atta virgule wa7da fil fichier, el empreinte tetbadel kamla. Hekka nethabtou eli el data ma tbadletch.

> **Chnowa l9ina (résultats réels du notebook)**
> - train : `963b5e22825b34d8…` — test : `3cda7109ce17bafb…`
> - `RUL_FD001.txt` : mawjoud, ama **ma t9rach w ma t7asbetlouch empreinte**.

Kifech t9oulha lel jury (en français)

« J'ai centralisé tous les paramètres et fixé la graine aléatoire pour que l'analyse soit reproductible ; les versions des bibliothèques et l'empreinte SHA-256 des données brutes sont tracées. »

Section 2 — Schéma du dataset et chargement

3lech : el fichiers **ma fihomch asami** lel colonnes (ghir 26 raqm fi kol ligne). Lezem n3atiwhom asami w n9raw train w test b **nafs el schéma**.

Extraits

```
SENSOR_COLUMNS = [f"sensor_{i}" for i in range(1, 22)]
df = pd.read_csv(path, sep=r"\s+", header=None, names=COLUMN_NAMES)
train_df.sample(5, random_state=RANDOM_STATE)
```

- `[f"sensor_{i}" for i in range(1, 22)]` → `sensor_1` … `sensor_21`.
- `sep=r"\s+"` : el valeurs mfar9in b **espaces** (wa7ed wala akther).
- `header=None` : el fichier ma fihech ligne titres. `names=` : n3atiwh el asami.
- `.sample(5, random_state=…)` : 5 lignes **b hasard** (reproductible). 3lech mouch `.head()` ? 5atr `.head()` ywarri dima moteur 1 fil cycles 1 à 5, ya3ni ken **bidayet el 3omr** → nadhra mghalta.

Chnowa l9ina (résultats réels du notebook)

- Train : **20 631 lignes**, 100 moteurs, cycles men 1 lel 362.
- Test : **13 096 lignes**, 100 moteurs, cycles men 1 lel 303.
- 26 colonnes fil zouz.

Ndher — attention

El fichier **ma y9ollekch** chnowa kol capteur. Ma t9oulech « `sensor_11` = température » : fil publication mte3 NASA (Saxena et al., 2008) fama asami, ama a7na ma nesta3mlouhomch. El analyse mte3na **statistique**.

Kifech t9oulha lel jury (en français)

« Une ligne correspond à l'état d'un moteur à un cycle donné ; les 20 631 lignes du train sont les observations successives de 100 trajectoires, pas des exemples indépendants. »

Section 3 — Contrôles de qualité et d'intégrité

3lech : data msakhra (cases fer8in, lignes m3awdin, cycle nakes fil wost) **tkhasser kol chay ba3d**. Nverifiw 9bal ma nersmou wala n7asbou.

Fonction quality_report — extrait

```
"missing_values":       int(df.isna().sum().sum()),
"duplicate_rows":       int(df.duplicated().sum()),
"duplicate_unit_cycle": int(df.duplicated(subset=["unit_id", "cycle"]).sum()),
"cycle_gaps":           int((steps != 1).sum()),
```

- `isna()` : yal9a les cases **fer8in** ; `.sum().sum()` yahsebhom fil tableau lkol.
- `duplicated()` : lignes **m3awdin** bedhabt.
- `duplicated(subset=["unit_id", "cycle"])` : moteur 3andou **zouz lignes fi nafs el cycle** (mosta7il).

- `steps` = far9 bin kol cycle w eli 9balou (`diff()`). Lezem dima **1** ; ken 2 → cycle nakes.
- Nverifiw zeda eli **kol moteur yebda men cycle 1**.

Contrôle	Résultat	Ma3neha
Colonnes non numériques	0	Kol chay t9ra ka raqm.
Valeurs manquantes	0	Ma lezemch nkammlou (imputation).
Valeurs infinies	0	Ma fama 7atta ±inf.
Lignes dupliquées	0	Kol ligne mokhtalfa.
Doublons (unit_id, cycle)	0	Moteur ma 3andouch zouz 7alet fi nafs el cycle.
Ruptures de cycles	0	El cycles mtab3in (1, 2, 3…).
Moteurs ne démarrant pas à 1	0	Kol trajectoire tebda men el bidaya.

Types : **22 colonnes réelles** w **4 entières** : `unit_id`, `cycle`, `sensor_17` w `sensor_18` → zouz capteurs **discrets** (ya5dhou ken 3dad s7a7).

> **Ochfa — à retenir**
>
> Data **nadhifa** ≠ data **mfida**. Nadhifa ya3ni ma fihech erreurs ; ama ynajjem ykoun fiha capteurs ma y9oulou chay (section 6).

> **Kifech t9oulha lel jury (en français)**
>
> « Les contrôles d'intégrité sont tous satisfaits : aucune valeur manquante, aucun doublon, des cycles continus qui commencent à 1 pour chaque moteur. Aucune imputation n'est donc nécessaire. »

Section 4 — Structure des trajectoires

3lech : n3arfou kol moteur 3ach 9adech. Ken el moteurs mokhtalfin barcha, hedha yaffecti el ta3lim w el évaluation.

```
train_lengths = trajectory_lengths(train_df)
q1, q3 = train_lengths.quantile([0.25, 0.75])
upper_fence = q3 + 1.5 * (q3 - q1)            # borne de Tukey
long_engines = train_lengths[train_lengths > upper_fence]
```

Statistique	Min	P5	Q1	Médiane	Moyenne	Q3	P95	Max	Écart-type
Cycles	128	147	177	199	206,31	229,25	287,3	362	46,34

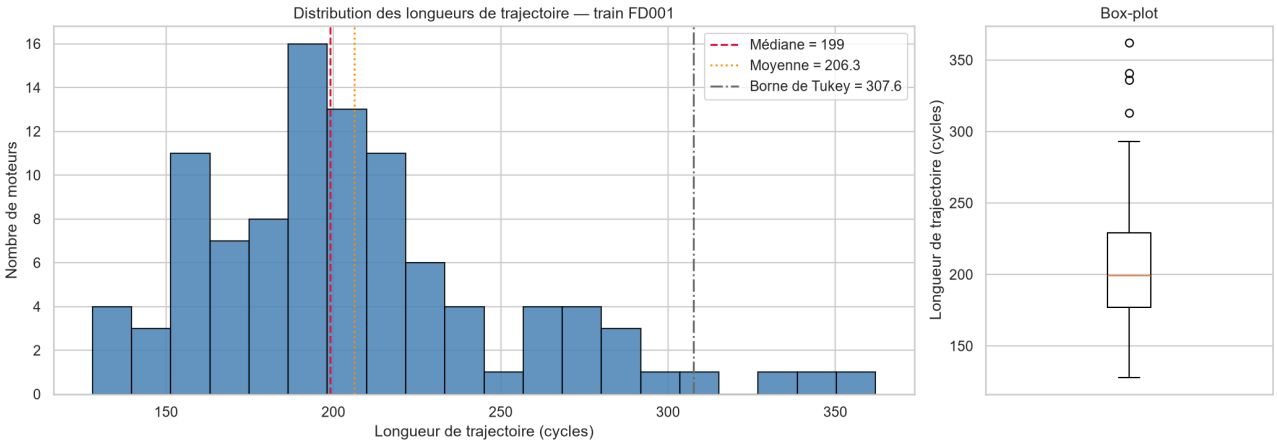


Figure — Distribution des longueurs de trajectoire (train FD001).

- Moyenne (206,3) **>** médiane (199) → distribution **asymétrique à droite** : chwaya moteurs 3achou barcha.
- Borne de Tukey = **307,6** → 4 moteurs atypiques : **67 (313), 96 (336), 92 (341), 69 (362)**.
- Mouch erreurs (el qualité behya) → **nkhalliwhom**.
- Moteur 69 ya3ti **362 ligne**, el moteur el a9sar ya3ti **128** → el modèle bech yetwazen akther 3al moteurs eli 3achou barcha. Lezem nevaluaw **moteur par moteur** zeda.

Kifech t9oulha lel jury (en français)

« Les durées de vie varient de 128 à 362 cycles ; les quatre moteurs au-delà de la borne de Tukey sont plausibles et conservés. Comme les moteurs longs fournissent plus de lignes, l'évaluation devra aussi être faite moteur par moteur. »

Section 5 — Split train / validation par moteur

3lech : hedhi **akther section mohemma** fil EDA. Lezem n9assmou el moteurs **9bal** ay analyse.

Fhemha b mithel

Ken n9assmou les **lignes** b hasard : moteur 26 ynajjem ykoun cycles 1–150 mte3ou fil train, w cycles 151–199 fil validation. El modèle « ya3ref » el moteur hedha deja → yjib note behya fil validation ama **mgharra**. Kif tlamidh chaf nafs el exercice fil examen blanc. Hedha **data leakage**.

El 7al : n9assmou **b moteurs kemlin** — kol moteur ykoun **ya fil train ya fil validation**, mouch fil zouz.

```
group_split = GroupShuffleSplit(n_splits=1, test_size=VALIDATION_SIZE,
                                random_state=RANDOM_STATE)
analysis_idx, validation_idx = next(
    group_split.split(train_df, groups=train_df["unit_id"]))

analysis_train = train_df.iloc[analysis_idx].copy()
validation_df  = train_df.iloc[validation_idx].copy()

assert analysis_engines.isdisjoint(validation_engines)
```

- `GroupShuffleSplit` (scikit-learn) : y9assem b **groupes**. `groups=train_df["unit_id"]` → el groupe = el moteur.
- `test_size=0.20` → 20 % mel moteurs (20 moteur) lel validation.
- `iloc[...]` : ya5ou les lignes b numérotation. `.copy()` : nos5a mosta9illa.

- `isdisjoint` : « ma fama 7atta moteur mochtarak ». Ken famma → `assert` yo9ef el notebook.

Chnowa l9ina (résultats réels du notebook)

- **80 moteurs** analyse (16 561 lignes) / **20 moteurs** validation (4 070 lignes) / **0** mochtarak.
- Validation : moteurs 1, 5, 11, 13, 19, 23, 31, 32, 34, 40, 45, 46, 54, 71, 74, 77, 78, 81, 84, 91.
- Moyenne des longueurs 207,0 contre 203,5 ; médiane 199 contre 193,5 ; max **362 contre 269**.

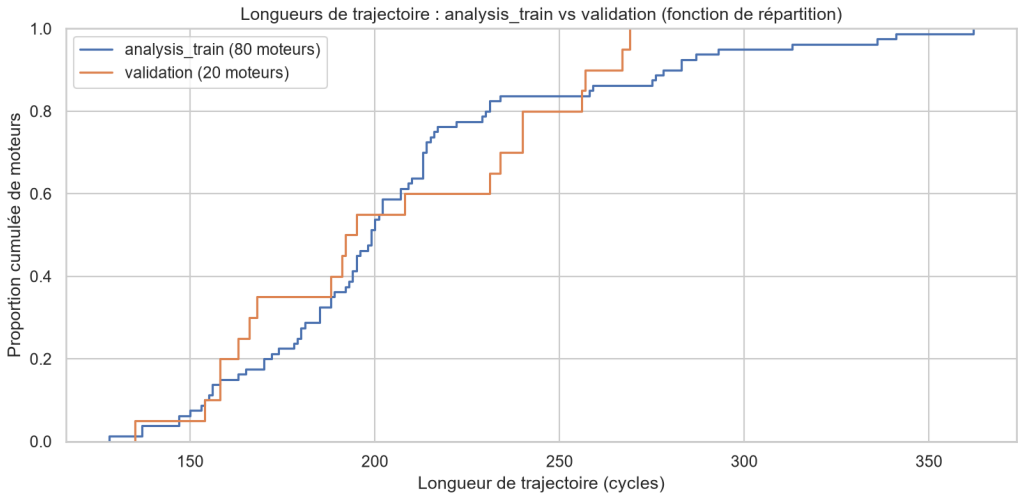


Figure — ECDF des longueurs : les deux courbes sont proches, sauf au-delà de 269 cycles.

Ndher — attention

Limite : fil validation ma fama 7atta moteur akther men **269 cycle**. Donc les RUL kbar (fou9 268) ma yet9aswech fil validation. B 20 moteur bark, split wa7ed fragile → fil étape 02 nesta3mlou **GroupKFold** (kol moteur yet3adda marra fil validation).

Ochfa — à retenir

Men houni l'e5er, kol analyse ta3mel 3la `analysis_train` **bark.** `validation_df` mrigel lel évaluation.

Kifech t9oulha lel jury (en français)

« Le split est fait par moteur avec GroupShuffleSplit : aucun moteur n'apparaît des deux côtés, ce qui évite la fuite d'information temporelle. Limite assumée : la validation ne contient pas de moteur de plus de 269 cycles, d'où la recommandation d'une validation croisée par groupes. »

Section 6 — Variabilité des variables

3lech : capteur **ma yetbadelch** ma y9ollek chay 3al moteur.

Fhemha b mithel

Montre wa9fa 3la 10:10 : dima nafs el valeur, ma t3allemek chay 3al wa9t. Capteur constant kif-kif.

3lech ma nesta3mlouch l'écart-type wa7dou ? 5atr kol capteur 3andou unité : wa7ed y9is 0,03 w lekhor 9 000. Écart-type sghir ma ya3nich capteur constant. Donc nesta3mlou **zouz critères ma ytbaddlouch b l'échelle** :

- `n_unique` : 9adech men valeur mokhtalfa chafha el capteur.

- `dominant_ratio` : el part mte3 el valeur el akther tekrar (1,0 = dima nafs el valeur).

```
def variability_category(row):
    if row["n_unique"] == 1:
        return "constante"
    if row["dominant_ratio"] >= NEAR_CONSTANT_THRESHOLD:     # 0.95
        return "quasi constante"
    return "dynamique"
```

Catégorie	Variables	Pourquoi
Constantes (7)	`setting_3`, `sensor_1`, `sensor_5`, `sensor_10`, `sensor_16`, `sensor_18`, `sensor_19`	Valeur wa7da bark.
Quasi constante (1)	`sensor_6`	21,61 fi 98,1 % mel lignes, 21,60 fi 1,9 %.
Dynamiques (16)	`setting_1`, `setting_2` + 14 capteurs : 2, 3, 4, 7, 8, 9, 11, 12, 13, 14, 15, 17, 20, 21	Yetbadlou fil wa9t.

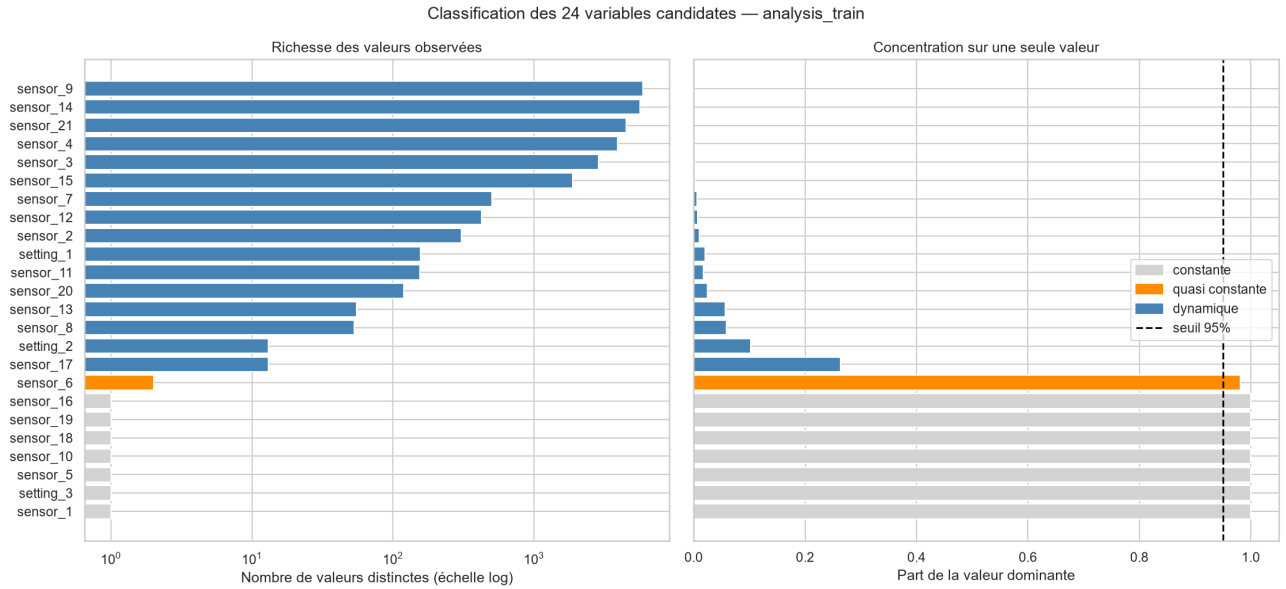


Figure — Classification des 24 variables : gris = constante, orange = quasi constante, bleu = dynamique.

- `sensor_5`, `sensor_10`, `sensor_16` 3andhom écart-type kif **0,000000000000005** : hedha **bruit d'arrondi** mte3 el ordinateur, mouch variation 7a9i9iya.
- `setting_1` w `setting_2` yetbadlou ama **9rib barcha mel 0** : FD001 fih condition wa7da.
- `sensor_17` : **13 valeur s7i7a** (388 → 400). `sensor_8` w `sensor_13` : 53 w 55 valeur → courbes « escalier ».

Ndher — attention

Fil version el 9dima, el seuil kén **99,5 %** w ma chafch `sensor_6` (98,1 %). Hedha 3lech twalla **95 %**. Variable quasi constante **ma tetfas5ch** : tet3allem bech nchoufouha (ablation) fil étape 02.

Kifech t9oulha lel jury (en français)

« Je classe les variables avec deux critères indépendants de l'échelle, le nombre de valeurs distinctes et la part de la valeur dominante. Sept variables sont constantes et seront retirées ; sensor_6 est quasi constante et sera testée par ablation. »

Section 7 — Analyse temporelle des trajectoires

3lech : nchoufou **kifech el capteurs yetbadlou m3a el wa9t**, ya3ni kifech el dégradation tban.

7.1 Moteurs représentatifs

Ma n5tarouch moteur « jmil » bel 9asd. El code y5tar **automatiquement** 3 moteurs : 9sir (P10), wostani (P50), twil (P90) → **moteur 93 (155 cycles), 26 (199), 86 (278)**.

7.2 Moyenne glissante causale

```
engine[sensor].rolling(ROLLING_WINDOW, min_periods=1).mean()
```

> **Fhemha b mithel**
>
> Moyenne mte3 notes mte3ek fil **10 devoirs lekhrin** : tna77i el « 7adh » mte3 devoir wa7ed w tewarri el tendance. **Causale** = tesst3mel ken el devoirs eli fetou, mouch eli jeyin — kif fil production, ma na3rfouch el mosta9bel.

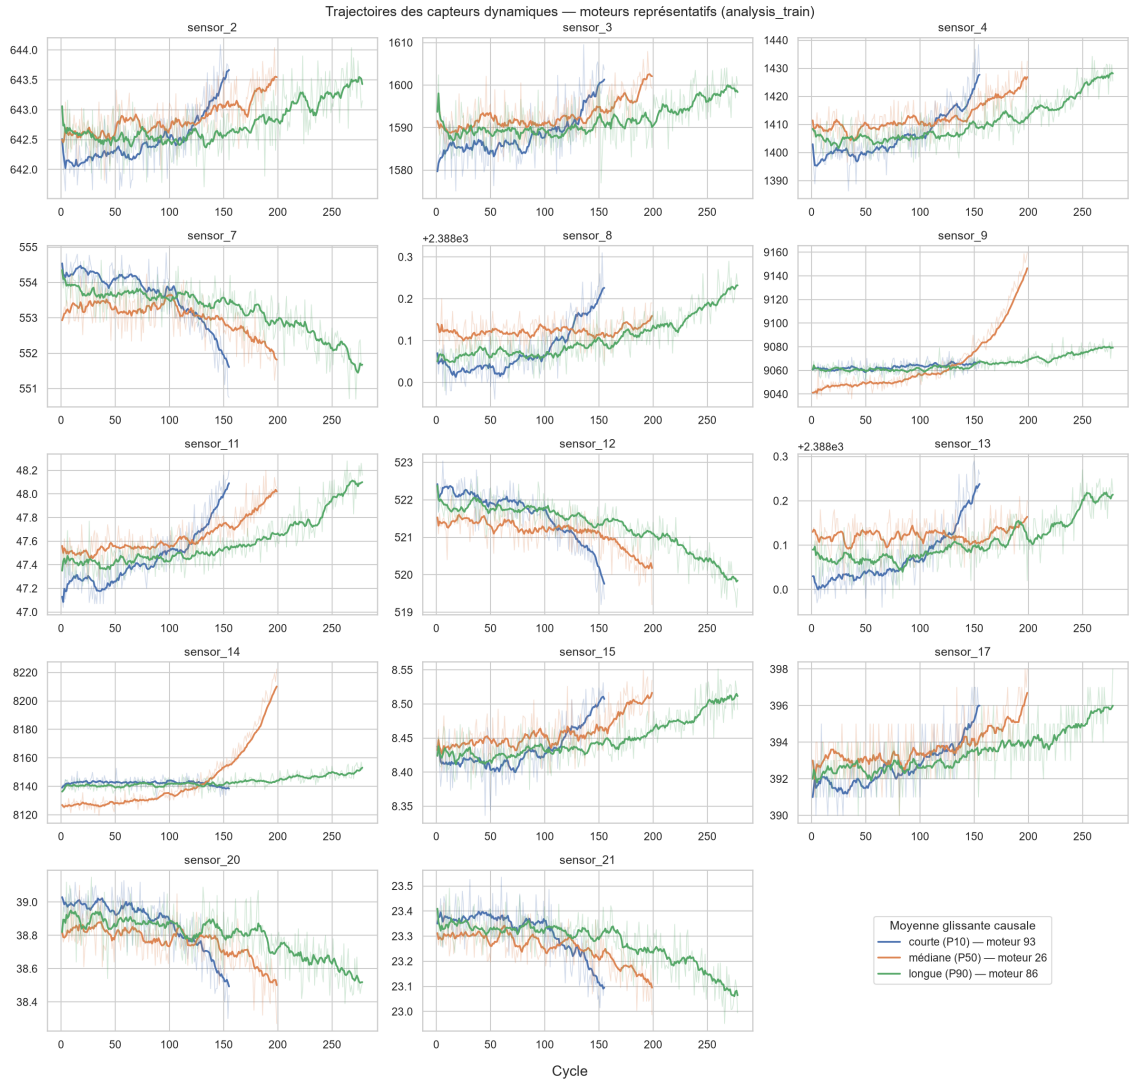


Figure — Trait clair : signal brut ; trait foncé : moyenne glissante causale (moteurs 93, 26, 86).

- El signal brut fih **bruit barcha** ; el moyenne glissante tewarri el tendance.

- El moteurs **ma yebdewch men nafs el niveau** (ex. `sensor_9` w `sensor_14` a9al lel moteur 26) : kol moteur 3andou usure initiale.
- El courbes **stables** barcha wa9t, ba3d **ytgallbou** 9rib el e5er → dégradation **non linéaire**.
- `sensor_4`, `7`, `11`, `12` : el 3 moteurs youslou **9rib nafs el niveau** fil e5er ; el 9sir youssel **asra3**.

7.3 Vue flotte en durée de vie normalisée

```
fleet_view["life_pct"] = 100 * fleet_view["cycle"] / \
    fleet_view.groupby("unit_id")["cycle"].transform("max")
...
del fleet_view          # suppression immédiate : variable interdite
```

`life_pct` = **9adech men %** mel 3omr el moteur fet (0 % = bidaya, 100 % = panne). Bih n9arnou el 80 moteur 3la nafs el échelle. Lkol tranche de 5 %, n7asbou el **médiane** w el **IQR** bin el moteurs.

> **Ndher — attention**
>
> `life_pct` **INTERDIT comme feature** : bech t7asbou lezmek ta3ref **win yemout el moteur** — ma3loma men el mosta9bel. Kif te9ra e5er el film 9bal ma tchoufou. Nesta3mlouh ken lel graphique w nfas5ouh toul (`del`).

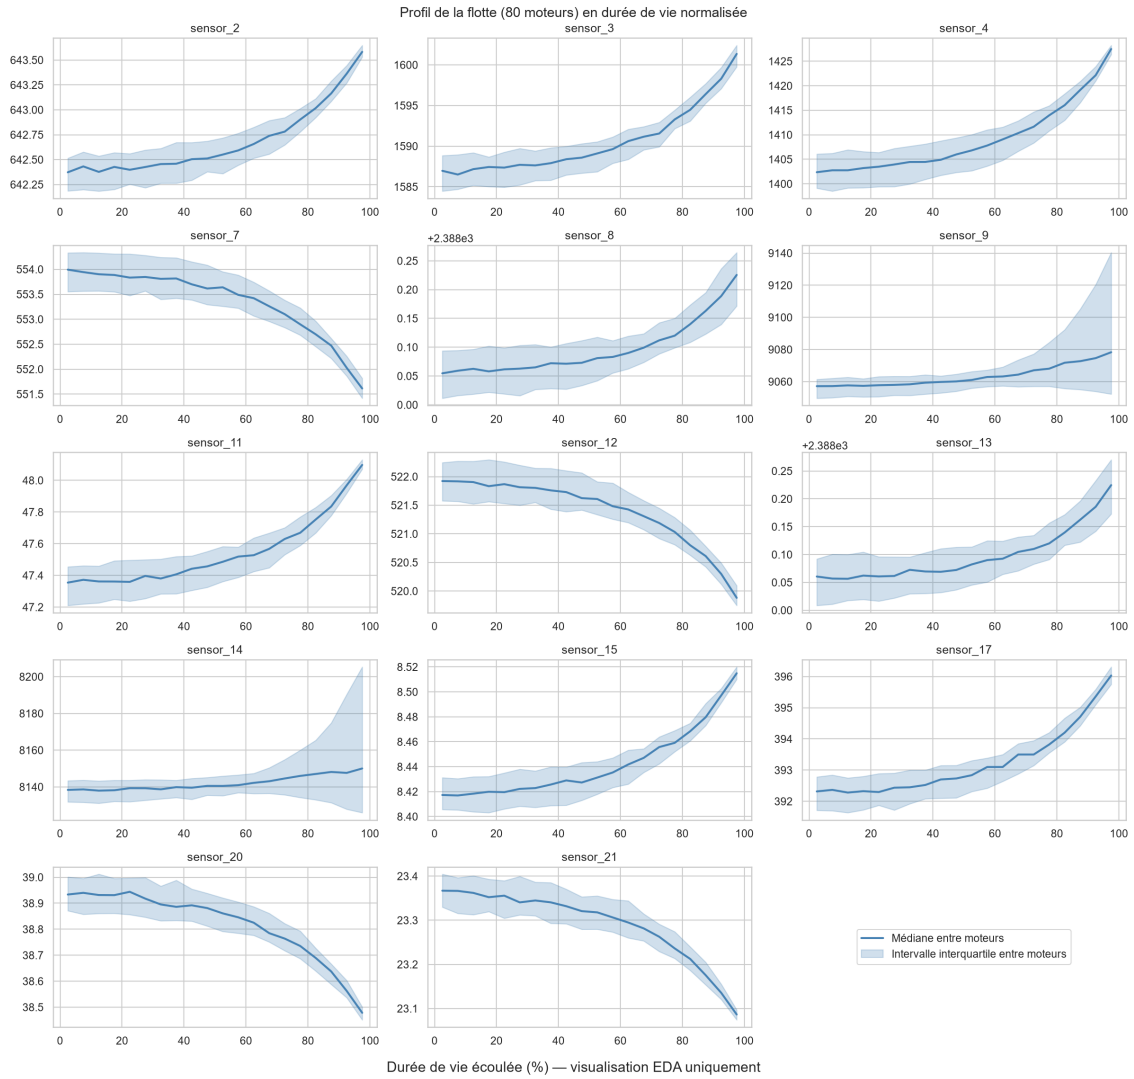


Figure — Médiane (trait) et intervalle interquartile (zone) des 80 moteurs, selon la durée de vie écoulée.

- **10 capteurs yetla3ou** 9rib el panne (2, 3, 4, 8, 9, 11, 13, 14, 15, 17) w **4 yahbtou** (7, 12, 20, 21).

- El évolution **tet2assra3** : bla7a fil noss el lowel, ba3d **asra3 w asra3** — el akthar fil **40 % lekhrin**.
- Lel 10 capteurs, el bande **tedh2a9** fil e5er : el moteurs yetla9aw fi 7ala nihaiya mtchabha.
- `sensor_9` w `sensor_14` : el bande **tetwassa3** → el moteurs yetfar9ou (section 11).

Kifech t9oulha lel jury (en français)

« Les capteurs évoluent de façon monotone mais non linéaire : stables pendant la première moitié de la vie, puis de plus en plus vite. Cela justifie des fenêtres temporelles, des modèles non linéaires, et l'hypothèse d'un RUL plafonné à tester. »

Section 8 — Construction et validation de la cible RUL

La formule : $RUL_{i,t} = T_i - t$, avec T_i = e5er cycle mte3 el moteur i, t = el cycle el 7ali.

Fhemha b mithel

Moteur 26 : T = 199. Fil cycle 1 → RUL = 198. Fil cycle 197 → RUL = 2. Fil cycle 199 → RUL = 0. Hedha bedhabt chnowa ywarri el notebook.

```
def add_rul(df):
    out = df.copy()
    out["RUL"] = out.groupby("unit_id")["cycle"].transform("max") - out["cycle"]
    return out
```

- `transform("max")` : yrodd **e5er cycle mte3 el moteur fi kol ligne**.
- `- out["cycle"]` : na7iw el cycle el 7ali → RUL.
- **Ma nkhalliwch colonne** `max_cycle` fil tableau : kenet bech twalli piège (fuite) ken el modèle yesta3melha.

Ba3d, `check_rul` ya3mel **5 contrôles** automatiques 3al analysis_train w 3al validation :

Contrôle	analysis_train	validation
RUL = 0 au dernier cycle	True	True
RUL = longueur − 1 au premier cycle	True	True
RUL décroît exactement de 1 par cycle	True	True
RUL entier et positif	True	True
Aucune colonne future conservée	True	True

8.2 RUL brut wala RUL plafonné ?

Fhemha b mithel

Karhba jdida : tnajjem t9oul « mezel 3andha barcha », ama ma tnajjemch tfar9 bin « mezel 300 000 km » w « mezel 250 000 km » 5atr kol chay yemchi mli7. **RUL plafonné** = n9oulou : ki el moteur sa7i7, el RUL mte3ou = maximum (ex. 125), w ma nebdewch n9assouh ken ki tebda el dégradation.

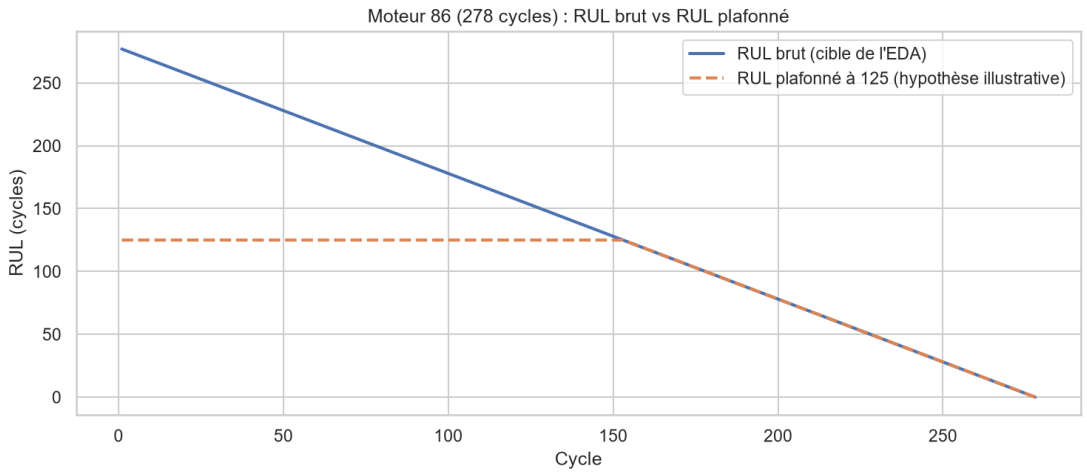


Figure — Moteur 86 : RUL brut (277 au cycle 1) et RUL plafonné à 125 (constant jusqu'au cycle 153).

Ndher — attention

125 = **mithel bark**. El RUL plafonné **hypothèse** : fil étape 02 n9arnou RUL brut m3a barcha plafonds 3al validation, w el meilleur yerba7. El EDA **ma t9arrerch**.

Kifech t9oulha lel jury (en français)

« La cible est RUL = T_i − t, calculée sans conserver le dernier cycle comme colonne, et validée par cinq contrôles automatiques. Le RUL plafonné est une hypothèse de modélisation que je comparerai au RUL brut en validation. »

Section 9 — Distribution de la cible RUL

3lech : n3arfou ama valeurs mte3 RUL **mawjoudin barcha** w ama **9lal** fil data.

Statistique	analysis_train	validation
Observations	16 561	4 070
Moyenne	108,38	105,49
Médiane	103	101
Écart-type	69,64	65,66
Maximum	361	268
Part RUL ≤ 125	60,87 %	61,92 %
Part RUL > 200	9,45 %	9,66 %

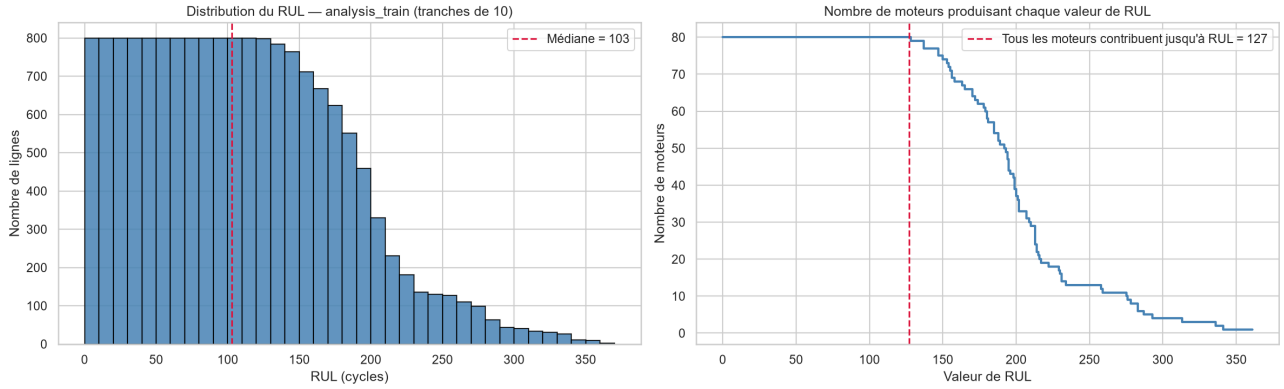


Figure — À gauche : histogramme du RUL ; à droite : nombre de moteurs qui produisent chaque valeur de RUL.

- **Plateau 0 → 127** : el moteur el a9sar 3ach 128 cycle → **el 80 moteur lkol** 3andhom ligne lkol valeur RUL men 0 lel 127.
- **Fou9 127** : valeur RUL `r` mawjouda ken lel moteurs eli 3achou akther men `r`. 13 moteur fet 250 cycle, w **4 bark** fetou 300.
- Chakl el distribution **jey men toul el trajectoires**, mouch phénomène physique.
- RUL **continu** → ma n9oulouch « classes déséquilibrées », n9oulou **couverture inégale**.

> **Ochfa — à retenir**
>
> Les RUL kbar = moteurs 9lal = prédictions **ma9tou3 fihom a9al**. Lezem nchoufou el erreur **par tranche** (bidaya / wost / 9rib el panne) — w 9rib el panne howa el mohem lel maintenance.

> **Kifech t9oulha lel jury (en français)**
>
> « La distribution du RUL découle directement des longueurs de trajectoire : tous les moteurs contribuent de 0 à 127, puis de moins en moins. Les grands RUL seront donc les plus incertains, et l'erreur sera analysée par tranche de RUL. »

Section 10 — Relations variables–RUL : Pearson et Spearman

3lech : nchoufou ama capteurs **yetbadlou m3a el RUL** — ya3ni ama capteurs « y7essou » bel dégradation.

```
corr_to_rul = pd.DataFrame({
    "pearson":  analysis_train[candidate_features].corrwith(
                    analysis_train["RUL"], method="pearson"),
    "spearman": analysis_train[candidate_features].corrwith(
                    analysis_train["RUL"], method="spearman"),
})
```

`corrwith` y7seb el corrélation mte3 **kol colonne** m3a el RUL. N7asbou Pearson **w** Spearman bech n3arfou el relation linéaire wala ken monotone.

Groupe	Variables	Spearman
Âge	`cycle`	−0,78 (Pearson −0,72)
Yetla3 9rib el panne	`sensor_11`, `4`, `15`, `17`, `2`, `3`, `8`, `13`	−0,71 → −0,56
Yahbet 9rib el panne	`sensor_12`, `7`, `21`, `20`	+0,68 → +0,65
Dh3if / mokhtalef	`sensor_9`, `sensor_14`	−0,32 ; −0,21
Walou	`sensor_6`, `setting_1`, `setting_2`	−0,12 ; ≈ 0 ; ≈ 0

> **Fhemha b mithel**
>
> **Signe négatif** (ex. `sensor_11` −0,71) : ki el RUL **yahbet** (el moteur ya9rab lel panne), el capteur **yetla3**. **Signe positif** (ex. `sensor_12` +0,68) : ki el RUL yahbet, el capteur yahbet zeda.

- `cycle` : relation **mécanique**. Fi moteur wa7ed, RUL = T − cycle → corrélation **−1 bedhabt**. Globalement −0,72 ken 5atr T yetbadel men moteur l moteur. `cycle` ma3rouf fil prédiction, ama el modèle ynajjem yesta3melou ka « raccourci » → **nejarbouh avec w sans**.
- Lel **12 capteur men 14**, Spearman **>** Pearson → relation **monotone ama mouch linéaire**.
- `sensor_9` w `sensor_14` : **Pearson > Spearman** w dh3if → comportement mokhtalef bin el moteurs (section 11).

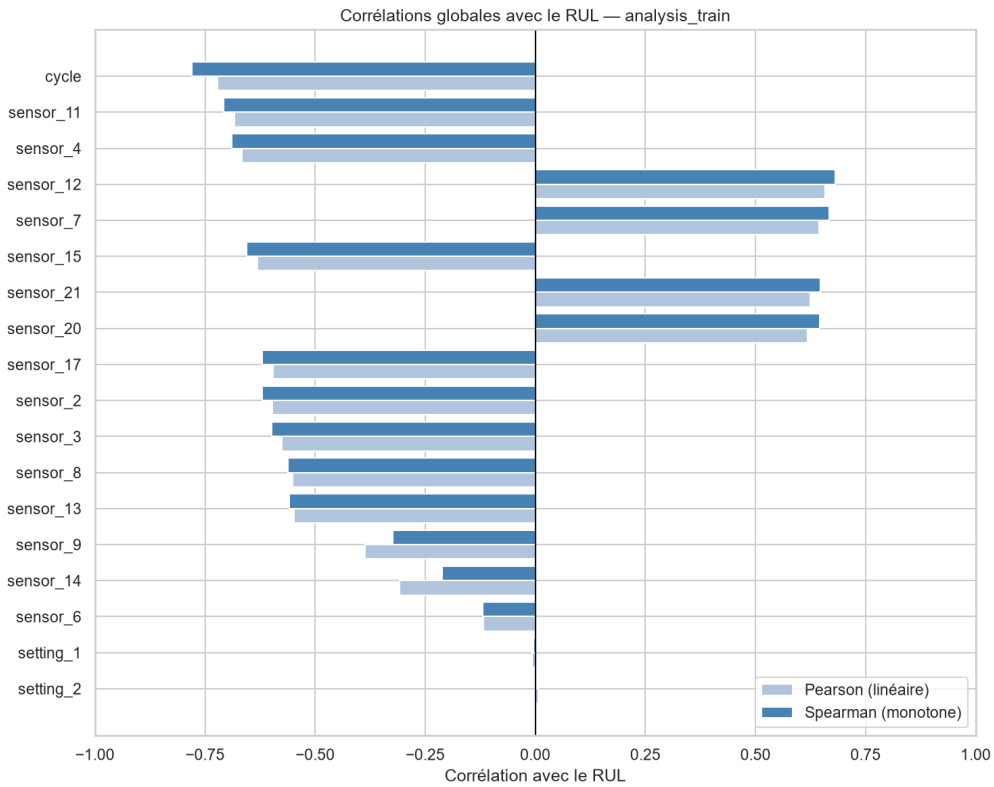


Figure — Pearson (clair) et Spearman (foncé) de chaque variable avec le RUL.

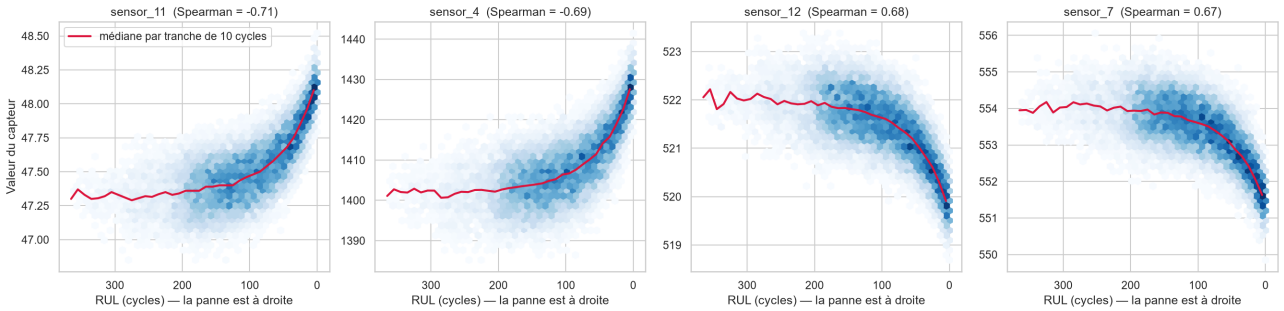


Figure — 4 capteurs les plus corrélés : densité des points (hexagones) et médiane par tranche de 10 cycles (rouge). La panne est à droite.

Fil figure lekhra : el ligne 7amra **bla7a** ki el RUL kbir, ba3d **tetgalleb** fil ~150 cycle lekhrin. Hedha 3lech Spearman > Pearson.

> **Ndher — attention**
>
> - Les lignes mte3 nafs el moteur **mouch indépendantes** → ma n7asbouch p-values.
> - Corrélation dh3ifa ≠ variable ma tasla7ch (relation non linéaire, interaction, tendance…).
> - **Ma nfas5ou 7atta variable** b sbab el corrélation.

> **Kifech t9oulha lel jury (en français)**
>
> « Douze capteurs ont une relation monotone nette avec le RUL, avec des coefficients de Spearman entre 0,56 et 0,71 en valeur absolue. Spearman dépasse Pearson, ce qui indique une relation monotone mais non linéaire. Ces corrélations servent à formuler des hypothèses, pas à sélectionner les variables. »

Section 11 — Robustesse des tendances au niveau moteur

3lech : el corrélation **globale** tnajjem t5abbi far9 bin el moteurs.

> **Fhemha b mithel**
>
> Moyenne mte3 9ism = 12/20. Ama ynajjem ykoun noss el 9ism 18 w noss 6. El moyenne t5abbi el 7a9i9a. Donc nchoufou **kol moteur wa7dou**.

```
def per_engine_spearman(df, sensor):
    correlations = {
        unit_id: engine[sensor].corr(engine["RUL"], method="spearman")
        for unit_id, engine in df.groupby("unit_id")
        if engine[sensor].nunique() > 1        # ignore les moteurs où le capteur est constant
    }
    return pd.Series(correlations, name=sensor, dtype=float)
```

- Lkol moteur (`groupby`), n7asbou Spearman bin el capteur w el RUL.
- `if engine[sensor].nunique() > 1` : ken el capteur **constant** 3and el moteur hedha, el corrélation ma3andhach ma3na → nfotou. Hedha y7el el **ConstantInputWarning** eli kén fil version el 9dima.

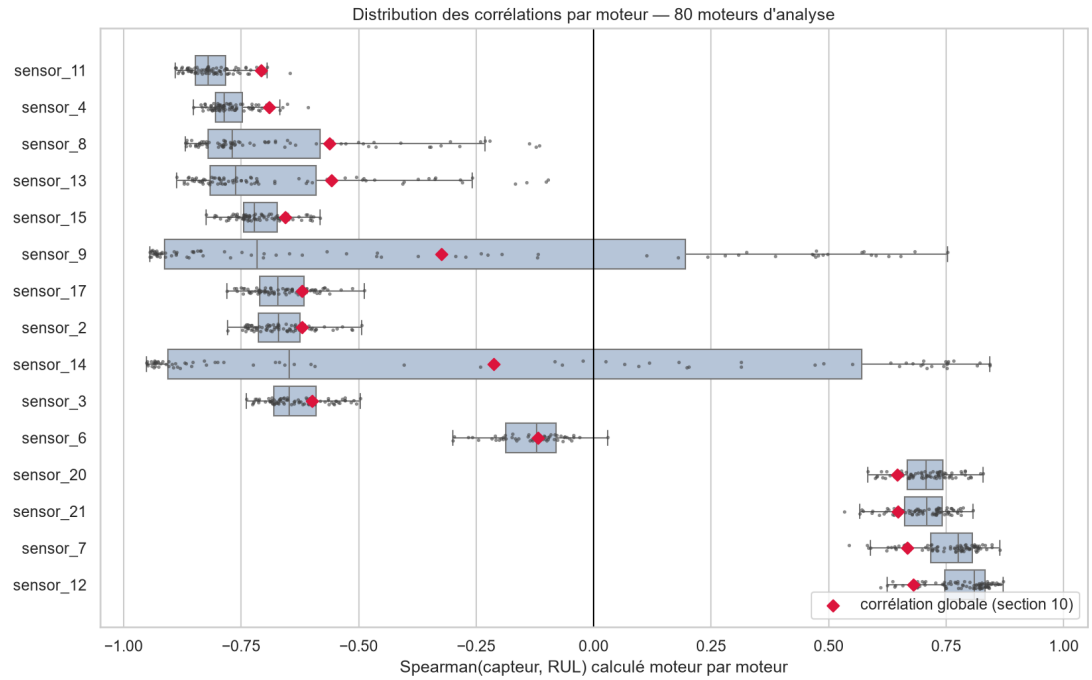


Figure — Chaque point = un moteur ; la boîte = la moitié centrale des moteurs ; le losange rouge = la corrélation globale.

Chnowa l9ina (résultats réels du notebook)

- **12 capteur men 14** : nafs el signe fi **100 %** mel 80 moteur → tendance **universelle**.
- Fil moteur wa7dou, el corrélation **a9wa** mel globale : `sensor_11` −0,82 contre −0,71 ; `sensor_8` −0,77 contre −0,56. 3lech ? Kol moteur yebda men niveau mokhtalef → ki n5altou el moteurs, el relation tetdha3ef.
- `sensor_6` : corrélation ken 3la 51 moteur (constant 3and 29 o5rin), médiane −0,12.

11.2 sensor_9 w sensor_14 : zouz régimes

	sensor_9	sensor_14
Moteurs ρ < 0 (yetla3 9rib el panne)	58	48
Moteurs ρ > 0 (yahbet 9rib el panne)	22	32
Longueur moyenne si ρ < 0	214,0	218,0
Longueur moyenne si ρ > 0	188,6	190,5
Spearman(ρ du moteur, longueur)	−0,31	−0,31

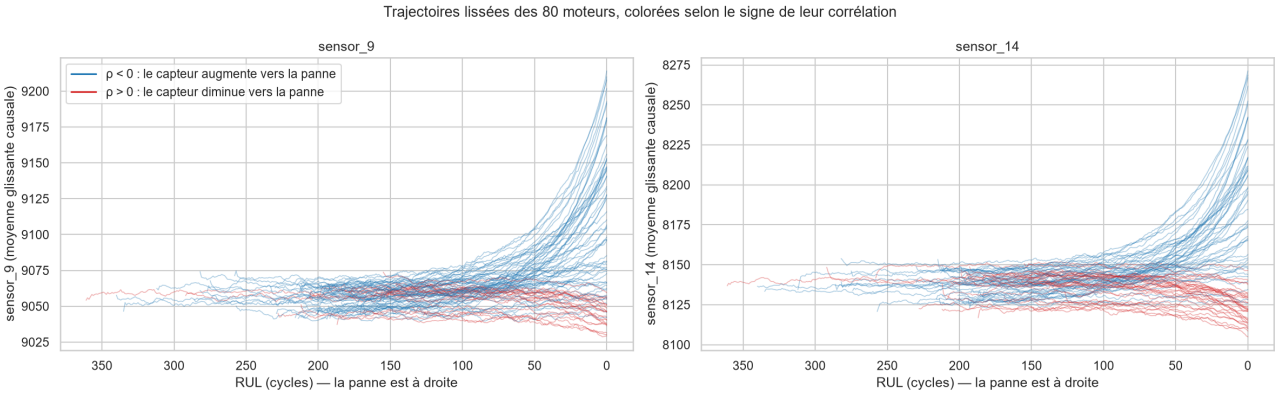


Figure — Les 80 moteurs : bleu = le capteur monte vers la panne ; rouge = il descend. Les deux familles se séparent dans les 50 à 100 derniers cycles.

- Fil bidaya, el moteurs lkol fi nafs el bande. **Fil 50 → 100 cycle lekhrin**, yetfar9ou : chwaya yetla3ou barcha, chwaya yahbtou chwaya.
- El moteurs eli el capteur yahbet 3andhom **a9sar 3omr** (≈ 25 à 28 cycle a9al). Relation **modérée**, w ma t9ollnech 3al sbab physique.
- **Ma nfas5ouhomch** : el far9 hedha ynajjem ykoun mfid lel modèle non linéaire. Nejarbouhom b **ablation**.

Kifech t9oulha lel jury (en français)

« En calculant la corrélation moteur par moteur, douze capteurs gardent le même signe sur 100 % des moteurs, et la relation est plus forte qu'au niveau global, car chaque moteur démarre à un niveau différent. sensor_9 et sensor_14 présentent deux régimes de fin de vie : je ne les supprime pas, je les testerai par ablation. »

Section 12 — Redondance entre variables

3lech : ken zouz capteurs y9oulou **nafs el 7aja**, wa7ed menhom ynajjem ykoun zeyed.

Fhemha b mithel

Zouz thermomètres fi nafs el bit : ywarriw nafs el température. Wa7ed yekfi — ama 9bal ma tna77i wa7ed, lezem tet2akked.

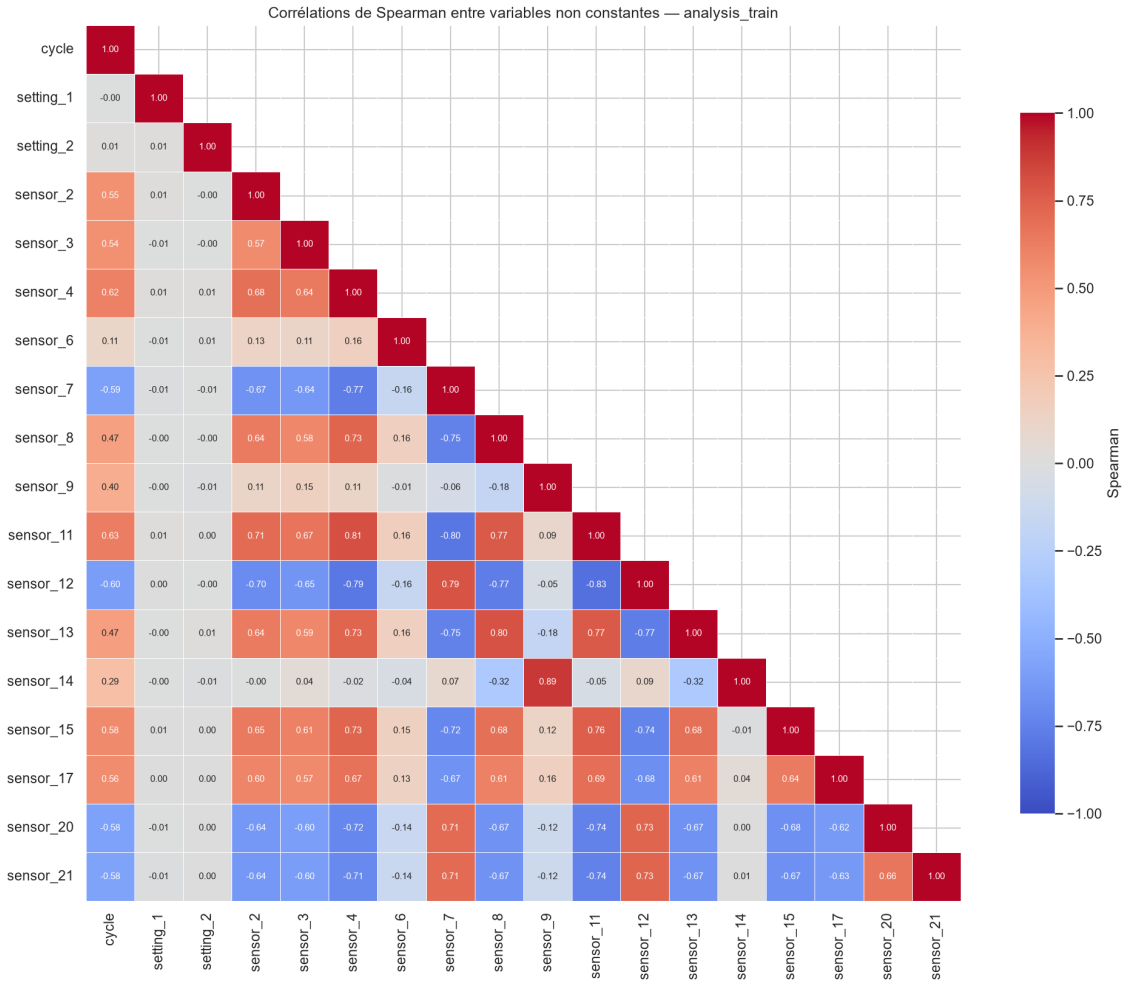


Figure — Matrice de Spearman : rouge = corrélation positive, bleu = négative.

Paire	Pearson	Spearman
sensor_9 – sensor_14	0,97	0,89
sensor_11 – sensor_12	−0,85	−0,83
sensor_4 – sensor_11	0,83	0,81
sensor_8 – sensor_13	0,83	0,80
sensor_7 – sensor_11	−0,82	−0,80
sensor_7 – sensor_12	0,81	0,79
sensor_4 – sensor_12	−0,81	−0,79

```
distance = 1 - analysis_train[cluster_sensors].corr(method="spearman").abs()
linkage_matrix = linkage(squareform(distance.to_numpy(), checks=False),
                         method="average")
```

Distance = 1 – |Spearman| : zouz capteurs mtchabhin barcha → distance 9rib men 0. El « coupe » 3la 0,20 ya3ni |Spearman| ≥ 0,80.

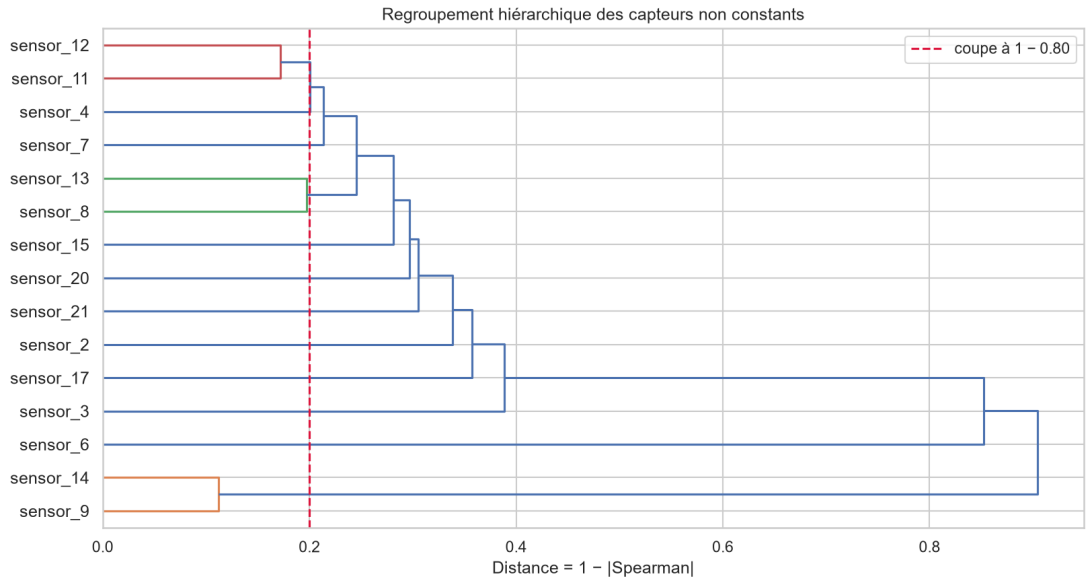


Figure — Dendrogramme : les capteurs reliés à gauche de la ligne rouge forment un groupe redondant.

- **3 groupes** : {`sensor_9`, `sensor_14`}, {`sensor_8`, `sensor_13`}, {`sensor_11`, `sensor_12`}.
- `sensor_4` w `sensor_7` yod5lou **juste fou9** el coupe → bloc {4, 7, 11, 12} mtrabet barcha.
- **Nuance :** jezé men el redondance jey men **tendance commune** : zouz capteurs yetbadlou fil e5er m3a ba3dhom 7atta ken y9isou 7ajet mokhtalfin.
- **Ma nfas5ou chay** : régression linéaire basita tet2assar b redondance ; Ridge w les arbres a9al.

> **Kifech t9oulha lel jury (en français)**
>
> « Sept paires dépassent 0,80 en valeur absolue, la plus forte étant sensor_9 / sensor_14 avec 0,97. Une partie de cette redondance vient de la tendance commune de dégradation ; je ne supprime rien à ce stade, la gestion dépendra du modèle. »

Section 13 — Audit anti-data-leakage

3lech : el cahier des charges y9ol eli el data leakage **« risque très élevé »**. Houni nektbou el **9awa3ed** : chnowa msmou7, chnowa nejarbouh, chnowa mamnou3.

Élément	Statut	3lech
`unit_id`	Clé de groupe, mouch feature	El modèle y7fadh el moteurs ; moteur jdid ma ya3rfouch.
`cycle`	Nejarbouh avec / sans	Ma3rouf fil prédiction, ama raccourci « âge ».
Capteurs dynamiques	Features candidates	Mesurés fil cycle el 7ali.
7 constantes	Nna77iwhom	Ma fihom chay.
`RUL`	Cible bark	Ma tod5olch fil X.
`last_cycle`, `max_cycle`	**INTERDIT**	Y9oulou win yemout el moteur.
`life_pct`	**INTERDIT** comme feature	Lezmou e5er cycle (EDA bark).
Moyennes glissantes	Msmou7a ken **causales**	Fenêtre centrée testa3mel el mosta9bel.
Scaler, sélection	Fit 3al train bark	Sinon el validation « t5addem » 3al ta3lim.
Fenêtres	Par moteur bark	Fenêtre ma t5alletch zouz moteurs.
`RUL_FD001.txt`	**Réservé au test final**	Ma y2assar 3la 7atta choix.

```
FORBIDDEN_COLUMNS = {"max_cycle", "last_cycle", "life_pct", "progress_pct"}
for name, df in datasets.items():
    leaked = FORBIDDEN_COLUMNS & set(df.columns)
    assert not leaked, f"{name} contient des colonnes interdites : {leaked}"
```

El code **yverifi automatiquement** eli 7atta tableau ma fih colonne mamnou3a. Ken l9a → el notebook yo9ef.

Kifech t9oulha lel jury (en français)

« Les variables qui révèlent la fin de trajectoire, comme le dernier cycle ou le pourcentage de vie, sont interdites et vérifiées absentes par des assertions. Le scaler et toute sélection seront ajustés uniquement sur les moteurs d'entraînement, et la vérité terrain du test n'est jamais lue. »

Section 14 — Contrôle structurel du jeu de test

3lech : nverifiw el **entrées** mte3 el test (mouch les réponses) bech n3arfou ken fihom mochkla, w chnowa les **contraintes** eli yfardhou.

Chnowa l9ina (résultats réels du notebook)

- Nafs les contrôles mte3 section 3 → **kol chay 0** w nafs el schéma.
- Test **ma9tou3** : médiane 133,5 cycle (contre 199 fil train), min **31**, max 303.
- Les 7 constantes 3andhom nafs el valeur fil test → nna77iwhom bla khouf.

El fenêtre W

Fhemha b mithel

El modèle LSTM ychouf **W cycle lekhrin** bech y9arrer (kif tchouf 30 vol lekhrin mte3 el avion). Ken el moteur 3andou 31 cycle bark w W = 50, ma 3andnach 50 cycle → lezem **padding** (n3abbiw).

W (cycles)	Moteurs test b a9al men W cycle	Part
20	0	0 %
30	0	0 %
50	**7**	7 %

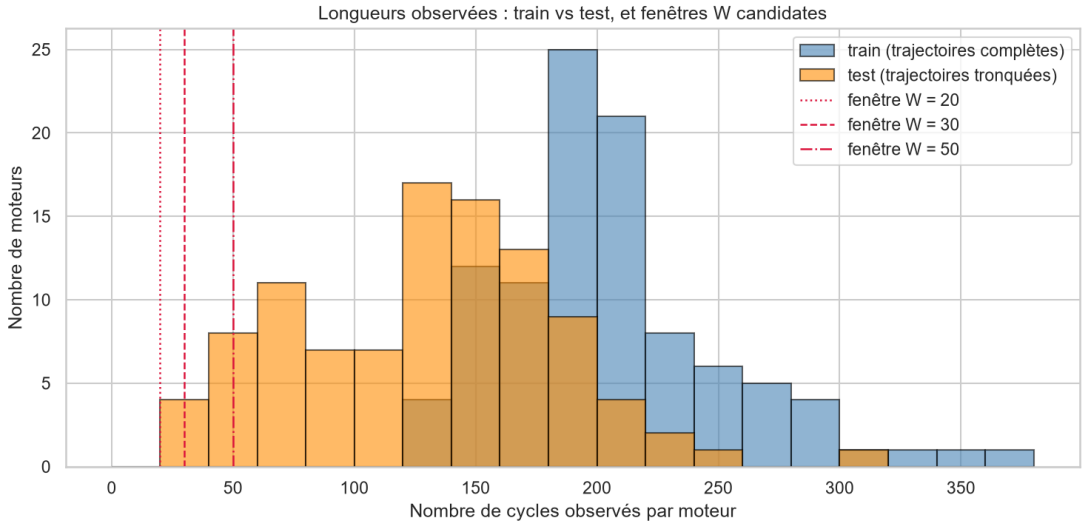


Figure — Longueurs observées : train complet (bleu) et test tronqué (orange), avec les fenêtres W candidates.

Cohérence train / test : la SMD

SMD = (moyenne test − moyenne train) / écart-type train. |SMD| a9al men 0,1 = far9 **négligeable**.

> **Ndher — attention**
>
> Ken n9arnou **kol el lignes**, nel9aw far9 kbir (7atta **0,46** lel `sensor_11`). Ama hedha 5atr el test **ma9tou3** : moteurs chafnehom fi bidayet 3omrhom. Kif t9aren tol sghar 10 snin m3a kbar 20 sna. Donc n9arnou **à stade de vie égal** : ken el **30 cycle lowlin**.

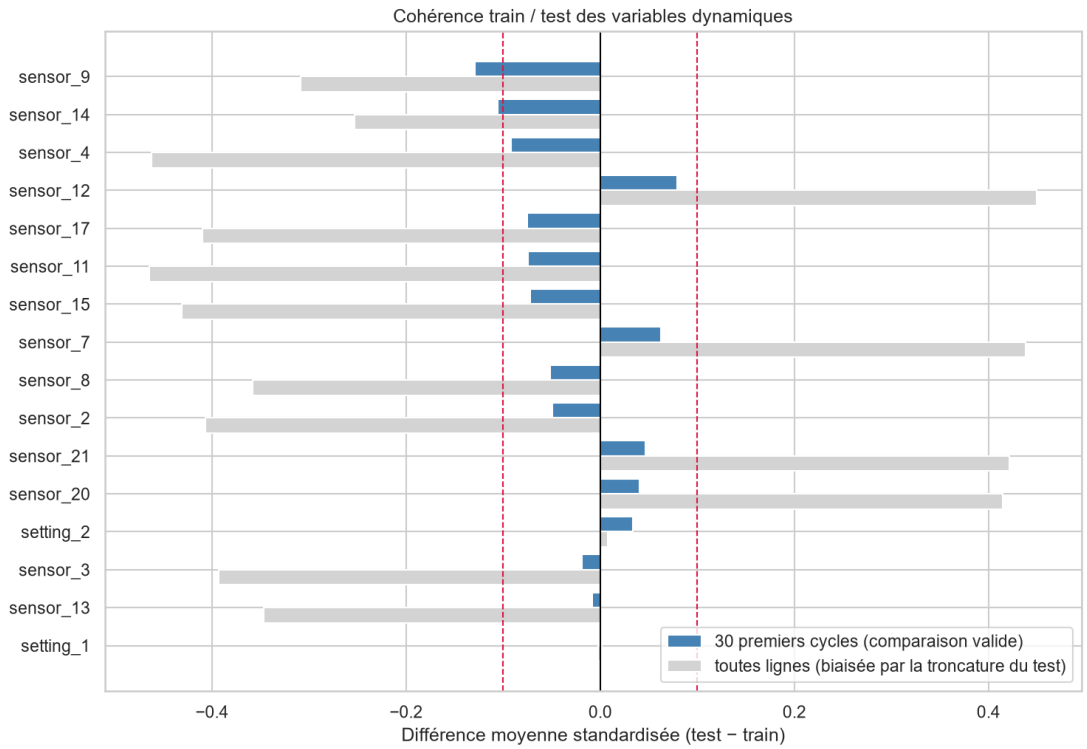


Figure — SMD sur les 30 premiers cycles (bleu, comparaison valide) et sur toutes les lignes (gris, biaisée).

- 30 cycle lowlin : kol |SMD| **a9al men 0,13**, w 14 variable men 16 a9al men 0,1 → train w test **men nafs el simulation**.
- Ma 9rinech `RUL_FD001.txt` w ma 5dhina 7atta 9rar men el test.

> **Kifech t9oulha lel jury (en français)**
>
> « Le jeu de test passe les mêmes contrôles que le train. Il est tronqué, avec au minimum 31 cycles par moteur : une fenêtre de 30 cycles s'applique à tous les moteurs, alors qu'une fenêtre de 50 imposerait du padding pour 7 moteurs. À stade de vie égal, les distributions sont cohérentes avec le train. »

Section 15 — Export des artefacts

3lech : el étape 02 lezemha **nafs el split** w **nafs les listes** de variables. Fi blaset ma n3awdou nektbouhom bel yed (w ngholtou), nsajlouhom fi fichiers JSON.

Fichier	Fih chnowa
`fd001_engine_split.json`	Numéros des moteurs analyse w validation, el graine, el méthode.
`fd001_feature_groups.json`	Constantes, quasi constantes, dynamiques, hétérogènes, groupes redondants.
`eda_fd001_summary.json`	Empreintes SHA-256 w chiffres clés.

Zeda, el notebook ysajjel **15 figure** fi `reports/figures/eda_fd001/` lel rapport.

> **Kifech t9oulha lel jury (en français)**
>
> « Les décisions de l'EDA sont exportées en JSON — split, groupes de variables, résumé — pour que l'étape suivante les réutilise sans recopie manuelle. »

Section 16 — Synthèse et décisions

El synthèse fiha tableau **résultats clés** w tableau **décisions** b statut :

- **Acquis** : 9rar mfrougha (ex. nna77iw les 7 constantes).
- **À valider** : hypothèse nejarbouha fil étape 02 (ex. RUL plafonné, ablation `sensor_6`).
- **Contrainte** : 7aja lezem nesta7mlouha (ex. W ≤ 30 bla padding).

El cellule de contrôle (el 7aja eli ta3ti 20/20)

```
checks = {
    "train : 20 631 lignes, 100 moteurs": train_df.shape == (20631, 26) and ...,
    "longueurs train 128 / 199 / 362": (...) == (128, 199, 362),
    ...
}
assert consistency.all(), "Chiffres du texte à mettre à jour : ..."
```

El cellule hedhi tverifi **automatiquement les 27 chiffre** el mektoubin fil texte. Ken ba3d nbadlou el data wala el code w raqm wa7ed ma3adch s7i7 → el notebook yo9ef. Hekka **ma yod5olch commentaire ghalet** fil rapport.

> **Fhemha b mithel**
>
> Kif correcteur automatique : 9bal ma tsalm el copie, yverifi eli kol raqm ktebtou fil réponse howa bedhabt eli 5raj fil calcul.

Section 17 — Conclusion scientifique

El conclusion tjaweb 3al **9 as2ila** mte3 el bidaya w tekteb les **limites** :

- Data **simulée** : ma nethkrouch 3la moteurs 7a9i9iyin.
- **FD001 bark** : condition wa7da, panne wa7da.
- Validation fiha **20 moteur bark**.
- Analyses b variable wa7da wala zouz : les interactions yel9ahom el modèle.

> **Ochfa — à retenir**
>
> El EDA **tlawwa7 hypothèses**. El modèles (étape 02) homa eli **y2akkdou wala yrafdhou**. Observation → hypothèse → validation.

Partie 7 — Préparation lel soutenance

7.1 Résumé fi 60 seconde (a7fdhou)

Résumé à dire au jury

« Avant toute modélisation, j'ai réalisé une analyse exploratoire du dataset NASA C-MAPSS FD001 : 100 moteurs simulés jusqu'à la panne, soit 20 631 observations. J'ai d'abord vérifié l'intégrité des données : aucune valeur manquante, aucun doublon, des cycles continus. J'ai ensuite séparé les moteurs en 80 pour l'analyse et 20 pour la validation, par moteur, afin d'éviter toute fuite d'information. J'ai identifié 7 variables constantes et 1 quasi constante, puis construit la cible RUL et vérifié sa cohérence automatiquement. Les capteurs montrent une dégradation monotone mais non linéaire, lente puis accélérée ; douze capteurs ont une tendance identique sur tous les moteurs, alors que sensor_9 et sensor_14 présentent deux régimes. Enfin, le jeu de test impose une contrainte concrète : 31 cycles minimum, donc une fenêtre de 30 cycles au plus sans padding. Toutes les décisions sont exportées, et chaque chiffre cité est vérifié automatiquement. »

7.2 Questions probables mte3 el jury

Q1. Pourquoi faire une EDA avant le modèle ?

Réponse : Pour vérifier la qualité des données, comprendre leur structure (100 trajectoires de longueurs différentes), repérer les variables inutiles et identifier les risques de fuite avant de construire le pipeline.

Q2. Pourquoi un split par moteur et pas un split aléatoire ?

Réponse : Les lignes d'un même moteur sont liées dans le temps. Un split aléatoire mettrait le même moteur des deux côtés : le modèle reconnaîtrait des trajectoires déjà vues, et les métriques seraient trop optimistes.

Q3. Pourquoi avoir séparé train et validation avant l'analyse ?

Réponse : Parce que les corrélations et la variabilité orientent des choix de modélisation. Si je les calculais aussi sur la validation, celle-ci aurait influencé mes choix et ne serait plus une évaluation indépendante.

Q4. Pourquoi ne pas avoir ouvert RUL_FD001.txt ?

Réponse : C'est la vérité terrain du test. Si je la regarde, elle peut influencer mes décisions et l'évaluation finale ne serait plus honnête. Elle est réservée au test final, une fois le pipeline figé.

Q5. Pourquoi Spearman en plus de Pearson ?

Réponse : Pearson mesure une relation linéaire, Spearman une relation monotone. Ici Spearman est plus élevé pour 12 capteurs sur 14 : la relation est monotone mais non linéaire, ce que Pearson seul sous-estimerait.

Q6. Pourquoi ne pas supprimer les variables peu corrélées ?

Réponse : Une faible corrélation ne prouve pas l'inutilité : une variable peut être utile par une relation non linéaire, une interaction ou sa tendance dans le temps. La décision sera prise par ablation en validation.

Q7. Pourquoi garder sensor_9 et sensor_14 ?

Réponse : Leur tendance diffère selon les moteurs, mais cette divergence en fin de vie peut être informative pour un modèle non linéaire. Je mesurerai leur apport réel avec et sans eux.

Q8. Qu'est-ce que le data leakage ? Un exemple dans votre projet ?

Réponse : C'est l'utilisation, pendant l'apprentissage, d'une information indisponible en conditions réelles. Exemple : une colonne « dernier cycle du moteur », qui donnerait directement le RUL. Elle est interdite et vérifiée absente.

Q9. Pourquoi la variable cycle est-elle « à tester » ?

Réponse : Elle est connue au moment de la prédiction, mais elle est liée mécaniquement au RUL. Le modèle pourrait s'appuyer sur l'âge moyen de la flotte plutôt que sur l'état réel du moteur. Je comparerai donc avec et sans.

Q10. Qu'est-ce que le RUL plafonné ? L'avez-vous utilisé ?

Réponse : C'est un RUL limité à un maximum tant que le moteur est sain. Je ne l'ai pas utilisé dans l'EDA : c'est une hypothèse, soutenue par la dégradation lente en début de vie, que je testerai en validation.

Q11. Quelle longueur de fenêtre allez-vous choisir ?

Réponse : Le test impose une contrainte : au minimum 31 cycles. W = 20 ou 30 s'applique à tous les moteurs ; W = 50 imposerait du padding pour 7 moteurs. Le choix final se fera par validation.

Q12. Quelles sont les limites de votre EDA ?

Réponse : Données simulées, un seul sous-ensemble (FD001), une validation de 20 moteurs sans trajectoire très longue, et des analyses uni- et bivariées qui ne captent pas les interactions.

Q13. Comment garantissez-vous la reproductibilité ?

Réponse : Graine fixe, paramètres centralisés, versions tracées, empreintes SHA-256 des données, artefacts exportés et une cellule qui vérifie automatiquement les 27 chiffres cités.

7.3 Erreurs lezem tetjanebhom fil oral

Ma t9oulech	9oul fi blasetha
« sensor_11 cause la panne »	« sensor_11 est associé à la baisse du RUL »
« La corrélation prouve que… »	« La corrélation suggère une hypothèse, à valider par le modèle »
« J'ai supprimé les variables faiblement corrélées »	« Je n'ai supprimé que les variables constantes ; le reste sera testé par ablation »
« sensor_11 est la température »	« Les capteurs ne sont pas nommés dans les fichiers ; l'analyse est statistique »
« J'ai 20 631 moteurs »	« J'ai 100 moteurs et 20 631 observations moteur-cycle »
« La validation, c'est le test »	« La validation sert à choisir ; le test sert uniquement à l'évaluation finale »

7.4 Fiche mémo : les chiffres clés

Thème	Chiffre
Train	100 moteurs · 20 631 lignes · 26 colonnes
Test	100 moteurs · 13 096 lignes · 31 à 303 cycles (médiane 133,5)
Durées de vie (train)	128 à 362 cycles · médiane 199 · moyenne 206,31 · écart-type 46,34
Moteurs atypiques	67, 96, 92, 69 (au-delà de 307,6 cycles)
Split	80 moteurs (16 561 lignes) / 20 moteurs (4 070 lignes) · validation ≤ 269 cycles
Variables	7 constantes · 1 quasi constante (sensor_6) · 16 dynamiques (14 capteurs)
RUL (analysis_train)	moyenne 108,38 · médiane 103 · max 361 · 60,87 % ≤ 125
Corrélations	12 capteurs |Spearman| 0,56 à 0,71 · sensor_11 = −0,71 (global), −0,82 (par moteur)
Hétérogènes	sensor_9 (58 / 22 moteurs) · sensor_14 (48 / 32 moteurs)
Redondance	7 paires ≥ 0,80 · sensor_9 – sensor_14 = 0,97
Fenêtre W	W ≤ 30 sans padding · 7 moteurs test < 50 cycles
Contrôle	27 chiffres vérifiés automatiquement

> **Ochfa — à retenir**
>
> Ma t7fadhch el code. **Efhem el 3lech** mte3 kol étape : 3lech split par moteur, 3lech ma n9rach RUL_FD001, 3lech ma nfas5ouch b corrélation, 3lech `life_pct` mamnou3. Ken fhemt el 3lech, tnajjem tjaweb 3la ay sou2el.